

Universidad Pontificia Comillas

ICAI

CUADERNO DE TRABAJO

Aprendizaje por refuerzo

Lydia Ruiz Martínez, Pablo Tuñón Laguna, Alberto Velasco Rodríguez

**APLICACIÓN DE CONCEPTOS GENERALES
DE RL**



Curso 2025-2026

Índice

1. Navegación con tile coding	2
1.1. Representación y generalización	2
1.2. Aproximación lineal e interpretación del gradiente	2
1.3. Recompensa en <code>step()</code> : diseño, escala y riesgos	2
1.4. Funciones <code>get_q_values</code> y <code>update</code>	3
1.5. Exploración y calendario de ϵ	3
1.6. Parámetros que mueven la aguja	3
1.7. Resultados y lectura de la figura	4
2. Operación en almacén	5

1. Navegación con tile coding

Esta sección documenta el diseño, las decisiones y los resultados de la práctica de navegación con aproximación lineal y tile coding. El objetivo es aprender una política que desplace al agente en un mapa de 10 m por 10 m hasta una zona objetivo evitando colisiones, usando acciones discretas de desplazamiento cardinal con paso de 0.25 m. Se parte de una observación cruda $(x, y, \text{collision}, \text{target})$ y se construye una representación dispersa mediante mosaicos solapados.

1.1. Representación y generalización

El estado continuo no se presta a una tabla de valores, así que se emplea tile coding con varias rejillas solapadas. Cada rejilla activa exactamente un índice, por lo que el vector de entrada $\mathbf{x}(s)$ tiene exactamente n_{tilings} unos y el resto ceros. La normalización por anchura y altura de tile desacopla la escala del mapa de la discretización. Se aplican desplazamientos distintos por rejilla con paso relativo $(3, 1)$ en los ejes para romper alineamientos regulares y evitar patrones repetitivos que degradan la generalización. Con $n_{\text{tiles_width}} = 10$, $n_{\text{tiles_height}} = 10$ y $n_{\text{tilings}} = 8$ se obtiene un compromiso útil: suficiente resolución para los pasillos entre obstáculos y suficiente solapamiento para transferir experiencia entre posiciones cercanas.

Los pesos se almacenan como una matriz $\mathbf{weights} \in \mathbb{R}^{\text{num_actions} \times \text{feature_size}}$. Esta forma evita ambigüedades de indexado y permite sumar de manera vectorizada en las columnas correspondientes a los índices activos.

1.2. Aproximación lineal e interpretación del gradiente

Se aproxima $Q(s, a)$ con un modelo lineal por acción,

$$Q(s, a) \approx \mathbf{w}_a^\top \mathbf{x}(s),$$

donde $\mathbf{x}(s)$ es binaria y dispersa. La derivada de Q respecto a $\mathbf{w}_a$ es exactamente $\mathbf{x}(s)$, por lo que el término de gradiente ya está implícito al actualizar únicamente las coordenadas activas. En la práctica, en cada transición se modifican n_{tilings} pesos de la fila asociada a la acción ejecutada. Esta propiedad justifica escalar la tasa de aprendizaje con el número de rejillas; como regla práctica, $\alpha \approx 0,1/n_{\text{tilings}}$ proporciona magnitudes razonables.

1.3. Recompensa en `step()`: diseño, escala y riesgos

El cálculo de la recompensa se integra en el método `step()`. Se usan tres casos:

$$r = \begin{cases} +100, & \text{si el agente entra en la zona objetivo,} \\ -100, & \text{si hay colisión,} \\ -c - k(|x - c_x| + |y - c_y|), & \text{en otro caso,} \end{cases}$$

donde (c_x, c_y) es el centro de la zona objetivo. El término L1 genera una pendiente constante hacia la meta y evita los efectos de la norma L2, que puede introducir ganancias no deseadas al cuadrar distancias y, lejos del objetivo, gradientes más pequeños de los que conviene. La escala de los extremos y del shaping es delicada: valores absolutos muy grandes en los terminales dominan la señal y pueden inducir trayectorias absurdas; valores demasiado pequeños en c y k dejan al agente sin guía intermedia. Una horquilla inicial razonable es $c \in [0,05, 0,1]$ y $k \in [0,005, 0,02]$. Si aparecen atascos por mínimos locales o colisiones sistemáticas, se reduce $|100|$, se incrementa c para penalizar pasos inútiles o se ajusta k para hacer más pronunciada la pendiente hacia el centro.

Cuando una acción intenta cruzar una pared, es preferible no actualizar la posición y terminar el episodio por colisión. El chequeo de llegada se realiza sobre la posición efectiva tras validar colisiones.

1.4. Funciones `get_q_values` y `update`

La función `get_q_values` suma los pesos en los índices activos para cada acción. La versión vectorizada

$$\text{q_values} = \text{weights[:, idx]}.sum(\text{axis}=1)$$

reduce coste frente a bucles anidados. La actualización en SARSA utiliza

$$\delta = \begin{cases} r - Q(s, a), & \text{si el episodio termina,} \\ r + \gamma Q(s', a') - Q(s, a), & \text{en caso contrario,} \end{cases} \quad \mathbf{w}_a \leftarrow \mathbf{w}_a + \alpha \delta \mathbf{x}(s).$$

En Q-learning se sustituye $Q(s', a')$ por $\max_{a'} Q(s', a')$. En ambos casos solo se actualizan las coordenadas activas, coherente con la derivada de la aproximación lineal.

1.5. Exploración y calendario de ϵ

La política de comportamiento es ϵ -greedy con decaimiento exponencial. La controlan tres parámetros: fracción de episodios a partir de la cual empieza el decaimiento, razón de decaimiento y valor mínimo. Si se empieza demasiado pronto o se usa una razón demasiado agresiva, la exploración se cierra antes de descubrir rutas útiles; si se empieza demasiado tarde, la política no se consolida. En los ensayos resultó equilibrado iniciar el decaimiento entre el cincuenta y el setenta por ciento de los episodios, con razón en el intervalo $[0,95, 0,99]$ y mínimo entre 0,02 y 0,05, de modo que la política sea casi determinista al final, en línea con el protocolo de evaluación.

1.6. Parámetros que mueven la aguja

Se fijaron $n_{\text{tiles_width}} = 10$, $n_{\text{tiles_height}} = 10$, $n_{\text{tilings}} = 8$, zona objetivo (2,5, 8, 1,0, 2,0), $\gamma = 0,99$ y episodios de entrenamiento 10,000. La tasa de aprendizaje y el calendario de ϵ fueron los diales más sensibles: reducir en exceso la razón

de decaimiento degradó el aprendizaje por cierre prematuro de la exploración; posponer en exceso el inicio del decaimiento ralentizó la convergencia. El refactor incluyó centralizar código, corregir la forma de `weights` a matriz bidimensional y exponer parámetros que estaban embebidos en el ciclo de entrenamiento.

1.7. Resultados y lectura de la figura

La figura 1 muestra retorno por episodio, media móvil (ventana 100), longitud de episodios y tasa de éxito.




Figura 1: Evolución de métricas con 10 000 episodios.

El retorno por episodio presenta caídas pronunciadas asociadas a colisiones durante fases exploratorias. La media móvil se estabiliza en torno a valores positivos cercanos a 7 u 8, señal de que la recompensa densa con L1 proporciona dirección sostenida sin depender exclusivamente del terminal. La longitud de episodios se concentra en valores bajos con colas largas compatibles con exploración de rutas alternativas. La tasa de éxito se sitúa cerca del cien por cien en ventanas recientes, con caídas puntuales coherentes con un valor de ϵ aún no nulo.

2. Operación en almacén